13 — Bayi Scraping & Churn Tahmini: Derinlemesine (Faz 5)

> **Felsefe:** Veriyi rakipten önce gör. Bayi siparişi azalmadan **3 ay önce** sinyali yakala. Bayi hareketlerini sosyal medya ve web sitesinden okuyarak rakibe **kaymadan** önce müdahale et.

---

1. Niye scraping?

1.1 Soru

> "Bayi X siparişi azaltmadan, hatta hesabı kapamadan, gidişatın bozulduğunu nasıl anlarız?"

Klasik ERP sadece **olduktan sonra** görür: "geçen ay sipariş yoktu". O zaman çoktan rakibe kaymıştır.

Erken sinyal kaynakları: 1. Bayi web sitesi: yeni ürün eklenmesi (rakip ürünü mü?), fiyat değişikliği, kampanya 2. Sosyal medya: Instagram/Facebook post sıklığı, etiketlenen markalar 3. Google Maps: yorum sayısı (bayi ne kadar aktif?) 4. E-ticaret: online satış var mı, hangi markalar görünür? 5. KVKK kayıtları, vergi kaydı, çağrı merkezi durumu (kapanmış mı?) 6. Sektör portalları: sanayim.net, bayi.net listelerinde değişiklik

1.2 Stratejik kazanım

Sinyal	Etki
Bayi sitesinde rakip ürün belirdi	Churn riski +30 puan
60 gün post atılmamış	Aktivite düşük, +20 puan
Yeni distribütörlük etiketi	Olası başka markaya geçti +50 puan
Yorumlarda "kapandı", "yok"	Operasyonel sorun +40 puan
Sitenin .com → .com.tr değişimi	Şirket yeniden yapılanma +15 puan
Site ssl süresi geçti	Aktiflik düştü +10 puan

Toplam churn skoru = 0-100 arası → 70+ bayi acil müdahale listesine.

---

2. Yasal sınırlar — KVKK, robots.txt, ToS

2.1 Yasal çerçeve

Mevzuat	Kapsam	Bizim durum
KVKK (TR)	Kişisel veri (isim, telefon, email)	Sadece **firma verisi** topluyoruz, kişisel değil
GDPR (AB)	Kişisel veri	AB bayileri için aynı kural
TCK 245-A	Bilgi sistemine yetkisiz erişim	**Sadece public veri**, login arkasına geçmiyoruz
TBK 49	Haksız fiyat	Bayinin fiyatını kopyalayıp altına satmıyoruz; sadece sinyal
robots.txt	Yasal değil ama etik	**Saygı gösteriyoruz** — Disallow olan yere bakmıyoruz
Site ToS	Sözleşme	Public içerikte tipik olarak ToS'a aykırı değil; case-by-case

2.2 Kırmızı çizgiler (asla)

- ❌ Login arkasına geçmek (bayi paneli, e-ticaret panel)
- ❌ Captcha bypass (reCAPTCHA, Cloudflare)
- ❌ Telefon numarası listesi çıkarmak (KVKK kişisel veri)
- ❌ Email harvesting (KVKK)
- ❌ Saniyede 10 isteği geçmek (DDoS algılama riski)
- ❌ User-agent gizleme/sahte (etik dışı)

2.3 Etik kurallar (yapılır)

- ✅ User-Agent: `MatPortalBot/1.0 (+https://matportal.com.tr/bot)` — açık kimlik
- ✅ robots.txt'e saygı (`robotparser` zorunlu)
- ✅ Crawl rate: domain başına **maks 1 istek/2 saniye**
- ✅ İçeriği saklarken **kaynak URL + scrape tarihi** birlikte
- ✅ Bayi açıkça "veri toplamasın" derse → silinir + blacklist
- ✅ KVKK aydınlatma metninde "rakip ve müşteri sitelerinden public veri topluyoruz" beyanı

2.4 Açıklığımız

Bayi sözleşmesine eklenir: > "MatPortal hizmetinin geliştirilmesi amacıyla bayinin **public** web ve sosyal medya hesapları izlenir. Toplanan veri sadece dahili kullanım içindir, üçüncü tarafa paylaşılmaz."

---

3. Teknik altyapı

3.1 Stack

Katman	Araç	Neden
Crawler framework	**Crawlee** (TypeScript)	Paspas backend ile uyumlu, queue/retry built-in
Browser automation	**Playwright**	JS-rendered siteler için
HTML parser	**Cheerio**	Static HTML için hızlı
Headless detection bypass	**playwright-extra** + stealth plugin	Sadece publicly erişilebilir siteler için
Proxy	**Bright Data** veya **Apify proxy**	IP banlanmamak için
Queue	**BullMQ** (Redis)	Iş kuyruğu, retry, scheduling
Storage	MySQL (`web_kazima_kayitlari`) + S3 (HTML snapshot)	Tutarlılık + audit

3.2 Mimari

```
┌──────────────────────────────────────────────┐
│  /admin/web-kazima — yönetici UI             │
│  - hedef listesi yönet                       │
│  - manual çalıştır                           │
│  - sonuç incele                              │
└──────────────────────┬───────────────────────┘
                       ↓
┌──────────────────────────────────────────────┐
│  Scheduler (BullMQ + cron)                   │
│  - haftalık tarama: tüm bayi siteleri        │
│  - günlük: yüksek öncelik bayilerin sosyal   │
│  - tetikli: yeni bayi eklendiğinde ilk tarama │
└──────────────────────┬───────────────────────┘
                       ↓
┌──────────────────────────────────────────────┐
│  Crawler workers (Crawlee)                   │
│  - robots.txt kontrolü                       │
│  - rate limit (1 req / 2 sec / domain)       │
│  - retry (max 3, exponential backoff)        │
│  - HTML snapshot S3'e                        │
│  - Parse → structured data                   │
└──────────────────────┬───────────────────────┘
                       ↓
┌──────────────────────────────────────────────┐
│  Sinyal Çıkarıcı (LLM destekli)              │
│  - HTML → "bu sayfada hangi markalar var?"   │
│  - Önceki snapshot ile diff                  │
│  - Sinyal listesi → DB                       │
└──────────────────────┬───────────────────────┘
                       ↓
┌──────────────────────────────────────────────┐
│  Churn Tahmin Motoru                         │
│  - Sinyal × ağırlık → churn skoru            │
│  - Eşik üstü → uyarı + dashboard             │
└──────────────────────────────────────────────┘
```

3.3 Crawl edilebilir kaynaklar

Kaynak	Tip	Sıklık	Yasal
Bayi web sitesi	Direkt URL	Haftalık	✅ public
Instagram (public)	Profil sayfası	Günlük	⚠️ ToS dikkat
Facebook page	Public sayfa	Haftalık	⚠️ ToS dikkat
Google Maps	Place Details API	Haftalık	✅ resmi API
Sahibinden.com bayi listesi	Public liste	Aylık	⚠️ ToS dikkat
sanayim.net	Public liste	Aylık	✅ public
TOBB üye listesi	Public	Aylık	✅ public
LinkedIn	Profil sayfası	—	❌ ToS izin vermiyor

LinkedIn: Yasal risk yüksek — kullanmıyoruz. Hunter.io / Apollo.io aracılığıyla zaten erişim var.

---

4. Sinyal türleri ve ağırlıklar

4.1 Tablo

Sinyal	Kaynak	Tespit yöntemi	Churn etkisi (puan)	Doğrulama gerek
Yeni rakip ürün listesinde	Bayi sitesi	Önceki vs şu anki HTML diff	+30	Yöneticiyle teyit
60+ gün post yok	Instagram/Facebook	Son post tarihi	+20	Mevsim mi normal mi?
Stok azalan kategorilerde “stokta yok”	Bayi e-ticaret	Ürün sayfası HTML	+25	Doğrulama yok
Müşteri yorum sayısı düşüşü	Google Maps	Aylık review count	+15	Mevsimsel kontrol
Negatif yorum oranı arttı	Google Maps	Sentiment analizi (LLM)	+20	LLM güven < 0.8 ise atla
Site SSL geçmiş	SSL kontrol	TLS handshake	+10	Otomatik
Domain expired	DNS	WHOIS	+50	Doğrulama yok
Çağrı merkezi otomatik mesaj	Telefon (manuel)	İnsan girişi	+40	İnsan onayı
Yeni distribütörlük markası	Sitedeki “markalarımız” sayfası	Diff	+50	Yöneticiyle teyit
Çalışan azalması (LinkedIn’siz)	İş ilanları portallarında bayi adı yok	Aylık tarama	+15	Doğrulama yok
Vergi mükellefi sorgu — kapalı	GIB API	Aylık	+60	Otomatik (kritik)

4.2 Skor toplama

```
function churnSkoruHesapla(sinyaller: Sinyal[]): {skor: number; risk: 'düşük'|'orta'|'yüksek'|'kritik'} {
  const ham = sinyaller.reduce((acc, s) => acc + s.puan * s.guven, 0);
  const skor = Math.min(100, ham);

  if (skor >= 70) return {skor, risk: 'kritik'};
  if (skor >= 50) return {skor, risk: 'yüksek'};
  if (skor >= 30) return {skor, risk: 'orta'};
  return {skor, risk: 'düşük'};
}
```

`guven` : 0.0-1.0. LLM'in sinyalden ne kadar emin olduğu. Düşük güven → puan azaltılır.

4.3 Aksiyon eşikleri

Risk	Aksiyon
Düşük (0-29)	Sessiz, dashboard'da yeşil
Orta (30-49)	Yöneticinin haftalık raporunda görünür
Yüksek (50-69)	Anlık email + dashboard sarı
Kritik (70+)	Anlık email + telefon araması listesi + dashboard kırmızı + AI öneri: "ne yapılmalı?"

---

5. HTML diff — değişiklik yakalama

5.1 Strateji

Her crawl sonunda HTML S3'e kaydedilir + structured parse DB'ye. Önceki versiyon ile karşılaştırılır.

5.2 Parse hedefleri (bayi sitesi)

Bölüm	Selector örneği	Çıkarılan veri
Markalarımız	`.brands a, .markalar img`	Marka isimleri listesi
Ürün kategorileri	`.product-category, nav.menu li`	Kategori adları
Kampanya bandı	`.banner-promo, .campaign-text`	Kampanya başlığı
İletişim	`[itemtype*="ContactPoint"], .contact-info`	Adres, telefon (KVKK için saklamaz)
Sosyal medya linkleri	`a[href*="instagram"], a[href*="facebook"]`	Hesap username'leri
Footer "powered by"	`footer .powered, .copyright`	Yazılım sağlayıcı (Shopify, WooCommerce vs.)

5.3 LLM destekli sinyal çıkarımı

HTML > 50KB için doğrudan LLM'e atılmaz, önce structured parse yapılır. Sonra:

```
PROMPT: "Aşağıda bir bayi web sitesinin önceki ve şu anki versiyonu var.
         Önemli değişiklikleri (yeni markalar, kampanyalar, kapanış uyarıları,
         operasyonel sorun belirtileri) JSON listesi olarak döndür."

GİRİŞ:  { onceki_markalar: [...], simdi_markalar: [...], kampanya_bandi: '...' }

ÇIKTI:
[
  {
    "tip": "yeni_marka",
    "deger": "RakipMarkaA",
    "guven": 0.95,
    "kanit": "markalar bölümünde önceden yoktu, şimdi var"
  },
  {
    "tip": "kampanya",
    "deger": "Yaz indirimi %30",
    "guven": 0.90
  }
]
```

LLM provider: **Groq (llama-3.1-70b)** — ucuz ve hızlı, structured output.

5.4 False positive kontrolü

- LLM güven < 0.8 → manuel onay kuyruğuna
- Aynı sinyal 2 hafta üst üste tekrarlanıyor → "doğrulanmış"
- Tek seferlik anomali → "şüpheli, gözle"
- Yöneticinin manuel "yanlış pozitif" işareti → modelden öğren

---

6. Sosyal medya — özel durum

6.1 Instagram (public)

Yasal: Public profil görüntülemek serbest. Login gerek olmadan görülebilen veri.

Teknik: - Doğrudan scraping zor (Instagram aktif olarak engelliyor) - Resmi Graph API: bayi izin vermek zorunda → düşük olasılık - **Pratik:** Apify "Instagram Scraper" actor → $0.50/1000 profil, ToS uyumlu

Toplanan: - Son post tarihi (60+ gün → aktivite düşük) - Takipçi sayısı trendi (3 ay düşüyor → aktiflik azaldı) - Etiketlenen markalar (rakip marka etiketi → kayma sinyali) - Hashtag kullanımı (#rakipmarka)

6.2 Facebook (public page)

Aynı yaklaşım: Apify Facebook Page Scraper.

6.3 Limit

- Bayi başına ayda **5 dakika scraping**
- Toplam 100 bayi × 5dk = 500dk/ay = 8 saat/ay (Apify ücreti ~$10/ay)

---

7. Çağrı merkezi & insan girişi

Otomatik scraping'in göremediği sinyaller için **manuel form**:

```
/admin/bayi/{id}/manuel-sinyal
- "Bayiyi aradım: kapalı / cevap yok / yeni numara"  → puan +40
- "Bayi şubeleştiğini söyledi"  → +30 puan (negatif olmayan ama dikkat)
- "Bayi rakibe geçtiğini söyledi"  → +100 (kritik, bağlantıyı sonlandır)
```

Saha ekibi mobil uygulamadan giriş yapar. Herhangi bir formal sinyal LLM'in göremediği bilgiyi yakalar.

---

8. Churn tahmin modelinin kendisi

8.1 Yaklaşım iki katmanlı

Katman	Yöntem	Çıktı
Kural bazlı	Sinyal × ağırlık toplamı	Anlık churn skoru
ML bazlı	Lojistik regresyon → XGBoost	"30/60/90 gün içinde sipariş kesilme olasılığı"

8.2 ML modeli

Hedef değişken: “60 gün içinde sipariş gelmeyecek mi?” (binary)

Özellikler: - Son 90 gün sipariş sayısı - Son 90 gün ciro - Sipariş aralığı standart sapması (düzensizleşiyor mu?) - Web kazıma sinyalleri (one-hot) - Sektör, bölge, ölçek (bayi metadata) - Son fatura yaşı - Ödeme gecikme sayısı

Algoritma: XGBoost classifier (binary)

Çıktı:

```
{
  bayi_id: 'BAY-042',
  churn_olasilik_30gun: 0.72,
  churn_olasilik_60gun: 0.85,
  churn_olasilik_90gun: 0.91,
  en_etkili_3_sinyal: ['site_yeni_marka', 'instagram_post_yok', 'odeme_gecikti'],
  oneri: 'Bu hafta içinde telefon araması + indirim teklifi'
}
```

8.3 Validasyon

- 6 ay sonra “gerçekten churn etti mi?” check
- Confusion matrix: precision, recall, F1
- Hedef: precision > 0.7 (yanlış alarm az)
- Recall < 0.5 olabilir (kaçırdıklarımız manuel sinyalle yakalanır)

---

9. UI — `/admin/bayi-radari`

9.1 Ana ekran

Heatmap matrisi: - Y ekseni: tüm bayiler - X ekseni: son 12 hafta - Hücre rengi: churn skoru

Top liste: 1. **Acil müdahale gereken** (kritik): bayi adı + sebep + öneri 2. **Riskli** (yüksek): yöneticinin haftalık takibi 3. **Stabil**: yeşil

9.2 Bayi detay (`/admin/bayi/{id}/radar`)

- Sinyal timeline (son 12 hafta)
- HTML snapshot karşılaştırma (öncesi / sonrası)
- Sosyal medya post timeline
- Önerilen aksiyonlar
- Aksiyon log: “20 Mart: arandı, kampanya teklif edildi → siparişler %20 arttı”

9.3 Aksiyon önerisi (LLM)

```
PROMPT: "Bayi BAY-042 için churn skoru 78. Sinyaller: rakip marka eklendi,
         60 gün post yok. Son 6 ayın sipariş geçmişi: ... Öneri ver:
         3 alternatif aksiyon, her biri için tahmini etkisi."

ÇIKTI:
[
  { aksiyon: 'Telefon araması + %5 ek iskonto', tahmini_etki: 'churn riski %78 → %50', maliyet: '5 dk + 8K TL/ay' },
  { aksiyon: 'Saha ziyareti + ürün eğitimi', tahmini_etki: 'churn riski %78 → %35', maliyet: 'tam gün + ulaşım' },
  { aksiyon: 'Bayi-spesifik kampanya', tahmini_etki: 'churn riski %78 → %60', maliyet: '15K TL kampanya bütçesi' }
]
```

10. DB şeması

```
CREATE TABLE web_kazima_hedefleri (
  id char(36) PK,
  bayi_id char(36),
  url varchar(500),
  tip ENUM('site','instagram','facebook','google_maps','linkedin'),
  oncelik ENUM('düşük','orta','yüksek','kritik'),
  sıklık ENUM('günlük','haftalık','aylık'),
  son_kazima datetime,
  sonraki_kazima datetime,
  aktif tinyint,
  notlar text
);

CREATE TABLE web_kazima_kayitlari (
  id char(36) PK,
  hedef_id char(36),
  baslangic datetime,
  bitis datetime,
  http_durum int,
  yanit_boyutu int,
  s3_yol text,                 -- HTML snapshot S3 yolu
  parse_basarili tinyint,
  hata text,
  parsed_data JSON
);

CREATE TABLE bayi_sinyalleri (
  id char(36) PK,
  bayi_id char(36),
  tip varchar(64),               -- 'yeni_marka', 'instagram_pasif' vb.
  deger varchar(500),
  kanit text,
  guven decimal(4,2),
  puan int,
  kaynak ENUM('web','sosyal','manuel','vergi','ml_model'),
  kaynak_kayit_id char(36),
  tespit_tarihi datetime,
  durum ENUM('yeni','dogrulandi','red','gozardi'),
  manuel_yorum text
);

CREATE TABLE churn_skor_gecmisi (
  id char(36) PK,
  bayi_id char(36),
  tarih date,
  skor decimal(5,2),
  risk ENUM('düşük','orta','yüksek','kritik'),
  aktif_sinyaller JSON,
  ml_olasilik_30 decimal(4,2),
  ml_olasilik_60 decimal(4,2),
  ml_olasilik_90 decimal(4,2),
  INDEX (bayi_id, tarih)
);

CREATE TABLE churn_aksiyon_log (
  id char(36) PK,
```

```
  bayi_id char(36),
  user_id char(36),
  aksiyon_tipi varchar(64),
  detay text,
  oncesi_skor decimal(5,2),
  sonrasi_skor decimal(5,2),
  yapildi_at datetime
);
```

---

11. Performans & maliyet

11.1 Ölçek

100 bayi × 5 hedef (site + 2 sosyal + Google Maps + e-ticaret) = 500 hedef Haftalık tarama × 4 hafta = 2000 kazıma/ay

11.2 Maliyet

Kalem	Aylık
Apify (Instagram + Facebook)	$10-20
Bright Data proxy	$15
S3 storage (1GB HTML snapshot)	$0.50
LLM (sinyal çıkarımı, Groq)	$5-10
Toplam	**~$30-45/ay**

11.3 Ölçeklendirme

- 500 bayi → 2500 hedef → ~$100/ay
- 1000 bayi → 5000 hedef → ~$200/ay

---

12. Açık karar noktaları (Faz 5)

1. **LinkedIn:** ToS yüzünden sıfır mı, Hunter.io üzerinden dolaylı mı? (Önerim: dolaylı)
2. **Instagram:** Apify $20/ay olur mu, manuel mi? (Önerim: Apify)
3. **Bayi ToS:** Sözleşmeye scraping maddesi koymak şart mı? (Önerim: koy)
4. **Churn ML eşiği:** 0.5 mi, 0.7 mi? (Önerim: 0.6 ortayolu)
5. **Sosyal medya kapsam:** sadece bayi mi, müşteri de mi? (Önerim: ilk faz bayi)
6. **HTML snapshot saklama süresi:** 90 gün mü, 1 yıl mı? (Önerim: 90 gün; sonra metadata sadece)

13. Faz 5 çıktı listesi

✅ Crawlee + Playwright kurulu, robots.txt + rate limit aktif ✅ DB tabloları ✅ `/admin/web-kazima` UI: hedef yönetimi ✅ Haftalık cron ile tüm bayi siteleri taranır ✅ HTML diff → sinyal çıkarımı (LLM) ✅ Sinyal × ağırlık → churn skoru (kural bazlı) ✅ ML modeli (XGBoost) eğitilmiş, validasyon raporu ✅ `/admin/bayi-radari` heatmap + top liste ✅ Saha aksiyon log: önce/sonra ölçümleme ✅ Aydınlatma metni + bayi sözleşme maddesi yazılı